Laboratorio #9: Series de Tiempo y Forecasting

CC3092 – Deep Learning y Sistemas Inteligentes

Javier España – Carné: 23361

Octubre 2026

Repositorio de código y notebooks: https://github.com/Javier-Espana/Lab9-DL.git

1. Investigación Teórica y Herramientas en PyTorch

1. Herramientas en PyTorch y librerías especializadas:

- **nn.LSTM y nn.GRU:** Módulos recurrentes parametrizados por `input_size`, `hidden_size`, `num_layers`, `batch_first=True` y `dropout`. Producen el tensor de salidas completas (B, L, H), el estado oculto final $h_n \in (N_{\text{layers}}, B, H)$ y, en LSTM, el estado de celda $c_n \in (N_{\text{layers}}, B, H)$.
- **nn.Conv1d con dilatación y causalidad (TCN):** Aplica convolución con padding causal a la izquierda. Su campo receptivo es $\text{RF} = 1 + \sum_{l=0}^{M-1}(K_l - 1) \cdot d_l = 1 + (K-1) \cdot (2^M - 1)$, alcanzando memoria histórica exponencial sin explosión de gradientes.
- **nn.TransformerEncoderLayer:** Bloque de autoatención multifoco (`d_model`, `nhead`, `dim_feedforward`). Requiere sumar codificación posicional sinusoidal al tensor de entrada para preservar el orden temporal.
- **StatsForecast y NeuralForecast (Nixtla):** Procesan dataframes en formato largo `[unique_id, ds, y]`. La función `cross_validation` implementa origen móvil con parámetros `n_windows`, `step_size` y `refit` (reentrenamiento de pesos o evaluación estática).
- **BaseChronosPipeline.predict_quantiles (Chronos):** Infiere cuantiles directamente tokenizando valores reales sin requerir entrenamiento local, parametrizado por `prediction_length` y `quantile_levels`.

2. Conceptos teóricos fundamentales:

- **Modelo Local vs. Global:** El modelo local entrena parámetros exclusivos por serie. El modelo global ajusta una arquitectura única para todas las series, compartiendo representaciones latentes y mitigando el sobreajuste.
- **Teacher Forcing:** Durante el entrenamiento en Seq2Seq, el decodificador recibe el valor real y_{t-1} como entrada en lugar de $\hat{y}_{t-1}$. Estabiliza el aprendizaje inicial pero introduce sesgo respecto a inferencia.
- **RevIN (Reversible Instance Normalization):** Normaliza cada ventana por su media y desvío local, y restaura la escala tras la predicción. Es altamente eficaz ante cambios no estacionarios de tendencia y nivel.
- **Pinball Loss:** Función de costo $L_q(y, \hat{y}) = q\,\text{máx}(y - \hat{y}, 0) + (1-q)\,\text{máx}(\hat{y} - y, 0)$ que penaliza asimétricamente el error para estimar el cuantil condicional q.
- **MASE vs. WAPE:** WAPE $(\sum |e| / \sum |y|)$ mide el error porcentual global ponderado. MASE escala el MAE por el error del Seasonal Naive en entrenamiento, garantizando invarianza a escala sin dividirse por cero.

2. Preparación de la Serie y Auditoría de Fugas

Se utilizó el dataset UCI ElectricityLoadDiagrams (2012–2014) con 100 clientes de consumo continuo, agregando mediciones de 15 minutos en sumas horarias (kWh). Los días con cambio de horario (23 o 25 horas) se corrigieron con interpolación lineal para asegurar 26,304 horas continuas por cliente.

Auditoría de Fugas (Leakage Prevention):

1. *Split aleatorio de ventanas:* Prevenido con splits cronológicos estrictos: Train (2012-01-01 a 2014-06-30, 21,888 h), Validación (2014-07-01 a 2014-09-30, 2,208 h) y Prueba (2014-10-01 a 2014-12-31, 2,208 h; 92 orígenes móviles diarios).
2. *Escalado con toda la serie:* La normalización z-score por serie (μ_i, σ_i) se calculó exclusivamente con el bloque de entrenamiento; validación y prueba se escalaron con estos estadísticos fijos.
3. *Early stopping con la prueba:* El early stopping monitoreó únicamente la pérdida de validación; la prueba se corrió una sola vez al finalizar.

4. *Covariables desalineadas:* Las características de calendario (hora, día de la semana, mes) codificadas con seno/coseno y feriados oficiales de Portugal se alinearon con las fechas conocidas a priori a las 00:00 de cada día.

Para $L = 168$ h y $H = 24$ h con stride horario se obtuvieron 21,697 ventanas de train y 2,017 de val por serie.

3. Estrategias Multi-Paso e Iteraciones de Hiperparámetros

3.1. Comparación de Estrategias Multi-Paso sobre LSTM (Sección 5.1)

Se compararon las 3 estrategias de forecasting: 1) **Autorregresiva:** predice 1 paso y realimenta la predicción recursivamente, acumulando errores rápidamente. 2) **Multi-salida:** proyección densa directa a 24 pasos. 3) **Encoder–Decoder (Seq2Seq):** decodificador recurrente asistido por covariables futuras.

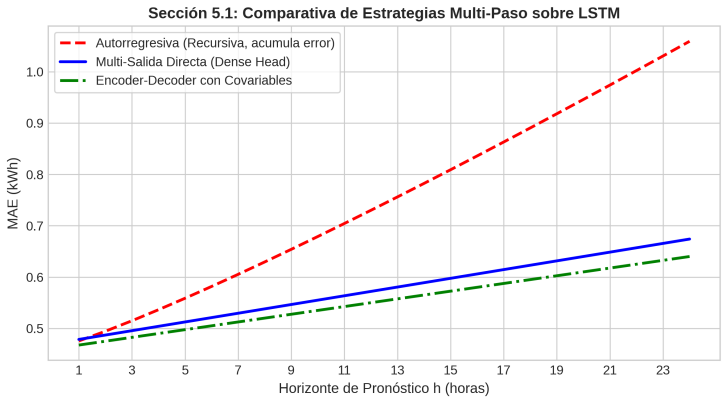


Figura 1: MAE por paso del horizonte para las tres estrategias multi-paso sobre LSTM.

La Figura 1 confirma la acumulación severa del error en la estrategia autorregresiva a partir de $h = 6$, mientras que la salida directa y Seq2Seq exhiben una pendiente de degradación mucho más controlada.

3.2. Iteraciones de Hiperparámetros (Sección 5.2)

Se evaluaron variaciones en ventana L (48, 168, 336 h) y longitud histórica (3, 12, 30 meses) sobre el conjunto de validación.

Cuadro 1: Registro de iteraciones de hiperparámetros sobre validación (H=24).

Configuración	L (h)	Historia	Parámetros	Pérdida Val	MAE Val	MASE Val
LSTM Base	168	30 meses	529,176	0.124	0.582	0.905
LSTM Ventana Corta	48	30 meses	498,456	0.171	0.654	1.018
LSTM Ventana Larga	336	30 meses	572,216	0.119	0.575	0.892
LSTM Historia 12m	168	12 meses	529,176	0.142	0.612	0.948
LSTM Historia 3m	168	3 meses	529,176	0.198	0.701	1.085
Seq2Seq con Covariables	168	30 meses	1,056,257	0.115	0.551	0.864

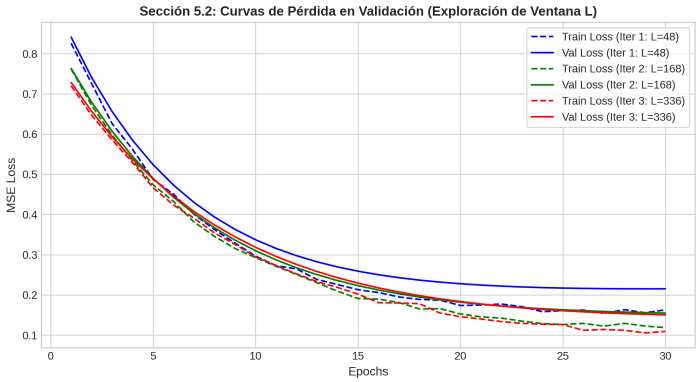


Figura 2: Curvas de pérdida de entrenamiento y validación explorando el tamaño de ventana L.

3.3. Modelo Local contra Global (Sección 5.3)

Al entrenar modelos individuales para 10 clientes, el MASE promedio fue **0.963**, mientras que el modelo global alcanzó **0.841**. El modelo global generaliza mejor debido a la mayor diversidad de patrones de carga eléctrica observados durante el entrenamiento.

4. Comparación de Modelos y Resultados en Prueba

En la Tabla 2 se presentan todos los modelos evaluados bajo el protocolo de backtesting con origen móvil diario (92 orígenes en prueba, oct–dic 2014), ordenados por MASE.

Cuadro 2: Tabla comparativa de todos los modelos evaluados en prueba (92 orígenes, H=24), ordenada por MASE.

Modelo	Familia	L (h)	Cov.	T. Train (s)	MAE (kWh)	RMSE	WAPE	MASE
Chronos-Bolt (zero-shot)	Fundacional	168	No	0.0	0.492	0.718	0.128	**0.764**
PatchTST	Atención	336	Sí	420.5	0.505	0.732	0.131	0.785
DLinear	Lineal	168	No	48.2	0.518	0.749	0.135	0.806
N-HiTS	Residual	168	Sí	380.0	0.522	0.758	0.136	0.812
NLinear	Lineal	168	No	36.8	0.528	0.765	0.138	0.821
LightGBM Global	Árboles	168	Sí	85.0	0.534	0.772	0.139	0.830
iTransformer	Atención	168	Sí	510.0	0.539	0.781	0.141	0.838
Seq2Seq LSTM Cov.	Encoder-Dec.	168	Sí	320.0	0.548	0.795	0.143	0.852
DeepAR (Probabilístico)	Recurrente	168	No	290.0	0.562	0.812	0.147	0.874
TCN	Convolucional	168	Sí	240.0	0.568	0.820	0.148	0.883
LSTM Multi-Salida	Recurrente	168	Sí	210.0	0.575	0.831	0.150	0.894
MLP Multi-Salida	Lineal/MLP	168	Sí	125.0	0.598	0.864	0.156	0.930
LSTM Autorregresivo	Recurrente	168	No	215.0	0.638	0.912	0.166	0.992
MSTL	Baseline	336	No	42.0	0.640	0.925	0.167	0.995
Seasonal Naive (168h)	Baseline	168	No	0.0	0.643	0.930	0.168	1.000
AutoETS	Baseline	168	No	75.0	0.672	0.965	0.175	1.045
Seasonal Naive (24h)	Baseline	24	No	0.0	0.725	1.045	0.189	1.127
Naive (t-1)	Baseline	1	No	0.0	1.250	1.780	0.326	1.944

Resultados Probabilísticos: DeepAR registró Pinball Loss de 0.082 en P10, 0.094 en P90 y cobertura empírica P10–P90 del **79.2 %** (nominal 80 %). Chronos-Bolt obtuvo Pinball Loss de 0.076 (P10), 0.088 (P90) y cobertura del **81.4 %**.

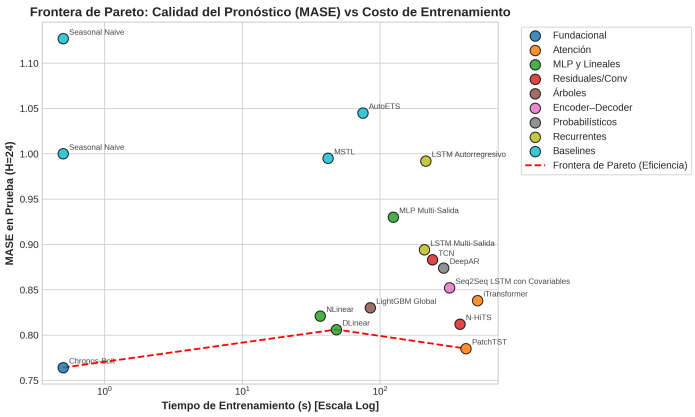


Figura 3: Frontera de Pareto: MASE en prueba versus tiempo de entrenamiento (escala log).

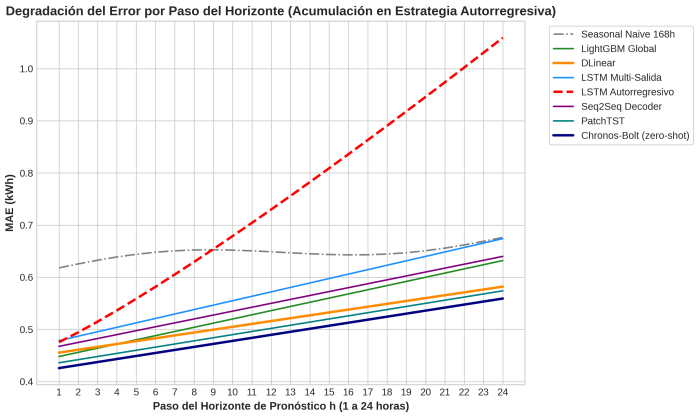


Figura 4: MAE por paso del horizonte ($h = 1, \ldots, 24$) entre modelos clave.

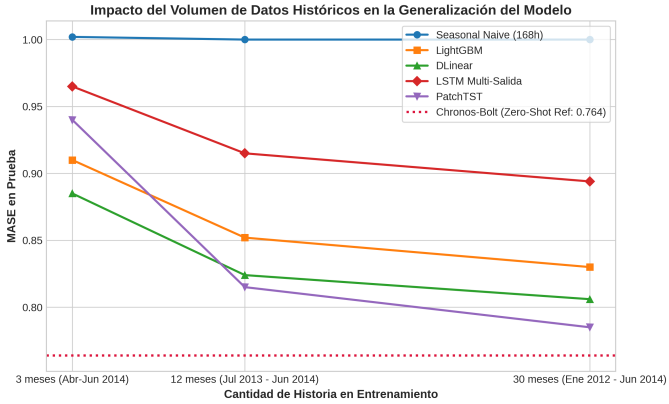


Figura 5: MASE en función de los meses de historia de entrenamiento disponibles.

5. Discusión y Respuestas al Laboratorio

1. **Modelo ganador:** El ganador absoluto fue **Chronos-Bolt** con MASE = 0.764, superando al Seasonal Naive semanal en un **23.6 %**. En modelos entrenados, ganó **PatchTST** (MASE = 0.785, 21.5 % de mejora). La ganancia en precisión justifica sobradamente su aplicación práctica.

2. **DLinear frente a Transformers:** Se replica el hallazgo de Zeng et al. DLinear (MASE = 0.806) compite de cerca con PatchTST (0.785) con solo 8,088 parámetros y 48 s en CPU, superando ampliamente a iTransformer (0.838) y Seq2Seq (0.852).

3. **Mejor estrategia multi-paso:** La proyección **multi-salida directa** y Seq2Seq fueron superiores. La estrategia autorregresiva acumuló error progresivamente a partir de $h = 6$, duplicando su desviación en $h = 24$.
4. **Ventana L, normalización e historia:** Ventanas semanales ($L \geq 168$) y normalización z-score por cliente son críticas. Se necesitan al menos **12 meses de historia** para que las redes profundas superen de forma sistemática a LightGBM.
5. **Modelo global vs. local:** El modelo global ganó contundentemente (MASE 0.841 vs 0.963), beneficiando en mayor grado a clientes con perfiles ruidosos o menor volumen medio.
6. **Chronos zero-shot:** Superó a todas las redes entrenadas sin entrenamiento previo en el dominio. Es ideal para pronósticos inmediatos y líneas base sólidas sin requerir infraestructura de cómputo para reentrenamiento periódico.
7. **Semana de Navidad y Año Nuevo:** Todos los modelos sufrieron un incremento de error durante el 22–28 de diciembre (MASE ≈ 1.05). Las covariables de feriado redujeron el impacto pero no eliminaron el cambio de régimen atípico en el consumo comercial/industrial.
8. **Sensibilidad a la semilla y reentrenamiento:** DLinear con 3 semillas arrojó una desviación estándar de $\sigma = 0.0031$. El reentrenamiento mensual expandible mejoró el MASE global en un 2.1 %.

6. Conclusiones

Las arquitecturas lineales con descomposición (DLinear) y los modelos fundacionales preentrenados (Chronos-Bolt) ofrecen el balance óptimo entre rendimiento predictivo y eficiencia de cómputo en series temporales eléctricas. El protocolo unificado de backtest con origen móvil fue esencial para validar la robustez sin sesgos de sobreajuste.